



Universidad Internacional de La Rioja
Escuela Superior de Ingeniería y Tecnología

Maestría en Ingeniería de Software y Sistemas Informáticos

Actividad 1. Informe De Segmentación De Clientes Mediante Aprendizaje no Supervisado

Fundamentos de inteligencia artificial

Estudiante: Miguel de Jesús Chávez Barragán

1. Introducción Buenas Terminó Primero.....	3
2. Objetivo.....	3
3. Descripción Del Dataset.....	3
3.1 Fuente De Datos.....	4
3.2 Estructura Del Dataset.....	4
3.3 Observaciones Iniciales.....	4
4. Análisis Exploratorio De Los Datos.....	5
4.1 Exploración Inicial.....	5
4.2 Estadística Descriptiva.....	6
4.3 Visualizaciones Principales.....	6
4.5 Interpretación Del Análisis Exploratorio.....	11
5. Preprocesamiento De Los Datos.....	11
5.1 Selección De Variables.....	11
5.2 Variables Excluidas.....	11
5.3 Escalado De Variables.....	13
6. Aplicación Del Primer Algoritmo De Clustering.....	13
6.1 Algoritmo Seleccionado.....	13
6.2 Búsqueda Del Número Óptimo De Clusters.....	14
6.3 Entrenamiento Del Modelo.....	16
6.4 Resultados Obtenidos.....	16
7. Aplicación Del Segundo Algoritmo De Clustering.....	18
7.1 Algoritmo Seleccionado.....	18
7.2 Parâmetros Utilizados.....	18
7.3 Resultados Obtenidos.....	18
8. Comparación De Algoritmos.....	20
8.1 Comparación Cuantitativa.....	20
8.3 Modelo Mas Adecuado.....	20
9. Aplicaciones En Un Contexto Real.....	21
10. Limitaciones Del Análisis.....	21
11. Conclusiones.....	21
13. Referencias.....	22

1. Introducción Buenas Terminó Primero

La segmentación de clientes es una técnica habitual en analítica de negocio porque permite agrupar personas con comportamientos parecidos y, con eso, tomar decisiones más precisas. En lugar de tratar a toda la base de clientes como un único bloque, el análisis no supervisado ayuda a detectar grupos con patrones de consumo distintos. Eso tiene valor para marketing, ventas, promociones y priorización comercial.

En esta actividad se trabajó con un conjunto de datos de clientes de un centro comercial. Las variables disponibles incluyen identificador del cliente, género, edad, ingreso anual y puntuación de gasto. El estudio se centró en identificar segmentos de clientes usando las variables numéricas y comparar dos métodos de clustering para decidir cual ofrece una mejor lectura de negocio.

La decisión de cuál ofrece mejor lectura proviene de un método llamado silhouette score o puntuación de silueta que es una puntuación atribuida a cada cluster por la distancia y entre más alto sea el puntaje es mejor.

2. Objetivo

Aplicar técnicas de clustering sobre un conjunto de datos de clientes para identificar grupos con características similares, comparar al menos dos métodos de segmentación y analizar la utilidad potencial de los resultados en un contexto real de negocio.

3. Descripción Del Dataset

El dataset que tenemos viene de parte de la de Kaggle que es la fuente que nos entrega un CSV Sobre clientes de un centro comercial En el CSV se encuentran 5 columnas, Con 200 registros. Es un dataset pequeño Pero suficiente Para practicar la segmentación y lectura de clusters Parte de las columnas que tiene el archivo bien información básica sobre los clientes Que nos va ayudar a explorar las relaciones entre las edades los ingresos y el comportamiento de compra.

3.1 Fuente De Datos

Tabla 1

Descripción general del dataset

Campo	Descripcion
Dataset	Mall_Customers.csv
Fuente	Kaggle, Mall Customers Dataset
Registros	200
Columnas	5
Contexto	Clientes de un centro comercial

3.2 Estructura Del Dataset

Las columnas del archivo son:

Columna	Tipo	Significado
CustomerID	Entero	Identificador del cliente
Genre	Texto	Genero registrado (Male o Female)
Age	Entero	Edad del cliente
Annual Income (k\$)	Entero	Ingreso anual en miles de dólares
Spending Score (1-100)	Entero	Puntuación de gasto de 1 a 100

3.3 Observaciones Iniciales

El dataset tiene una forma sencilla de leer, pero eso no significa que su estructura sea simple. La edad y el ingreso muestran dispersión moderada, mientras que la puntuación de gasto cubre casi toda la escala posible. Esa mezcla sugiere que existen segmentos comerciales distintos, no una población uniforme.

4. Análisis Exploratorio De Los Datos

4.1 Exploración Inicial

La revisión inicial muestra lo siguiente:

- Resultado de shape: (200, 5)
- Tipos de datos: cuatro columnas numéricas y una categórica
- Valores nulos: no se detectaron
- Duplicados: no se reportan en el análisis documentado

Columnas:

```
['CustomerID', 'Genre', 'Age', 'Annual Income (k$)', 'Spending Score (1-100)']
```

Info:

```
<class 'pandas.DataFrame'>
```

```
RangeIndex: 200 entries, 0 to 199
```

```
Data columns (total 5 columns):
```

```
# Column Non-Null Count Dtype
```

```
--- -----
```

```
0 CustomerID 200 non-null int64
```

```
1 Genre 200 non-null str
```

```
2 Age 200 non-null int64
```

```
3 Annual Income (k$) 200 non-null int64
```

```
4 Spending Score (1-100) 200 non-null int64
```

La ausencia de nulos reduce el trabajo de limpieza. En este caso el preprocesamiento se concentró en seleccionar las variables útiles y estandarizarlas.

```
CustomerID 0
```

```
Genre 0
```

```
Age 0
```

```
Annual Income (k$) 0
```

```
Spending Score (1-100) 0
```

```
dtype: int64
```

4.2 Estadística Descriptiva

Tabla 2

Resumen estadístico principal


Variable		Media	Desviacion estandar	Minimo	Mediana	Maximo
Age		38.85	13.97	18	36.00	70
Annual Income (k\$)		60.56	26.26	15	61.50	137
Spending Score (1-100)		50.20	25.82	1	50.00	99

Resumen estadístico principal: La edad promedio es 38.85 años. La distribución va de clientes jóvenes a clientes mayores, con una mediana de 36 años. El ingreso anual promedio es 60.56 k\$, con una dispersión amplia y una mediana cercana a la media. La puntuación de gasto tiene una variación fuerte y cubre casi toda la escala, lo que facilita encontrar grupos con conductas de consumo diferentes.

4.3 Visualizaciones Principales

Figura 1

Histogramas de variables numéricas




El histograma de edad muestra a los clientes desde 18 años de edad hasta los 70 años se nota una concentración importante más en edades jóvenes y adultas tempranas Especialmente entre los 20 y 40 años.

Por otro lado tenemos el histograma de ingreso anual Que muestra que muchos clientes tienen ingresos promedio entre 40 y 85000 dólares También tenemos en clientes con ingresos muy muy bajos cercanos de los 15 y 30 y muy pocos por encima de 100.

Por último El histograma de El puntaje De gasto Muestra valores repetidos De todo rango pero tenemos una concentración mayor entre 40 y 60 Aunque tenemos Muchos clientes de bajo y alto Estas últimas para una segmentación porque existen diferencias reales en el comportamiento y en la capacidad de pago También se podría determinar como una capacidad de pago diferencial dependiendo las edades o el gasto económico que tengan las personas

Figura 2

Boxplots de variables numericas



El boxplot De edad muestra una mediana acerca de los 36 años aunque la caja cubre aproximadamente de los finales de los 20 acerca de los 49 años No notamos una valor esa típico aquí.


Donde sí notamos valores atípicos provienen de boxplot De ingreso anual donde mostramos Un punto atípico acerca de los 137 lo cual indica que tenemos un cliente De alto ingreso bastante arriba que la mayoría.

Y por último el boxplot de gasto Tiene una mediana cercana de los 50 puntos La caja relativamente amplia lo cual confirma que hay una variación En el gasto nos observan valores atípicos marcados.

Los boxplots muestran clientes con valores extremos, sobre todo en ingreso y gasto. No se eliminaron, porque no parecen errores de captura. Al contrario, probablemente representan segmentos reales: personas con alto ingreso y bajo gasto, o clientes con bajo ingreso y gasto alto. En un análisis de segmentación, eliminar esos casos sin criterio puede borrar justamente los perfiles más útiles.

Figura 3

Dispersión entre ingreso anual y puntuación de gasto



Este gráfico de dispersión es 1 de los más importantes del análisis dado que muestra claramente que los clientes no están distribuidos como una nube completamente aleatoria sino hay zonas que podemos reconocer


- Ingreso bajo y gasto bajo.
- Ingreso bajo y gasto alto.
- Ingreso medio y gasto medio.
- Ingreso alto y gasto bajo.
- Ingreso alto y gasto alto.

Son justamente las candidatas naturales para los clusters, Por ejemplo podemos ver que tenemos clientes de alto ingreso y Gasto alto que pueden ser un segmento atractivo para campañas De marketing y en cambio también se nota que tenemos muchos clientes de alto de

ingreso alto y gasto bajo que podrían requerir estrategias de activaciones o distintos promociones Para poder incentivar el gasto.

Figura 4

Pairplot de variables numericas



El pairplot permite revisar relaciones entre todas las variables numéricas al mismo tiempo.

La relación más clara aparece entre Annual Income (k\$) y Spending Score (1-100). Se ven regiones separadas que luego los algoritmos de clustering intentan formalizar.

La relación entre Age y Spending Score sugiere que muchos clientes jóvenes tienen puntuaciones de gasto altas o medias, mientras que clientes mayores tienden a concentrarse más en gasto medio o bajo. No es una regla absoluta, pero sí un patrón visible.

La relación entre Age y Annual Income no muestra una separación tan fuerte. Por eso la edad ayuda, pero no parece ser la variable que más define los grupos visualmente.

4.5 Interpretación Del Análisis Exploratorio

Las visualizaciones ayudan a ver tres cosas. Primero, el ingreso y el gasto no crecen de forma lineal, así que hay espacio para clusters distintos. Segundo, la edad influye en parte del comportamiento, pero no domina todo el patrón. Tercero, el plano Annual Income (k\$) y Spending Score (1-100) ya sugiere grupos naturales. Esa es la razón por la que el clustering tiene sentido aquí.

5. Preprocesamiento De Los Datos

5.1 Selección De Variables

Para el clustering principal se usaron:

```
["Age", "Annual Income (k$)", "Spending Score (1-100)"]  
Run
```

Estas variables se eligieron porque son numéricas, comparables y tienen sentido directo para segmentar clientes. Permiten construir grupos por etapa de vida, capacidad económica y comportamiento de gasto.


5.2 Variables Excluidas

- **CustomerID**: se excluyó porque solo identifica registros.
- **General**: se excluye en el modelo base porque es categórica y no aporta una lectura cuantitativa inmediata sin transformación adicional.

Al incluir género en el algoritmo se pudo usar como una dimensión adicional de distancia. el género no esté correlacionado otras variables, al estar estándar puede separar clientes hombres y sugiere que género no tiene una uso fuerte con las variables numérica gráfica de K-Means sin género muestra la segmentation principal ya se e bastante bien por ingreso, gasto Por eso, cuando se agrega genero, modelo fragmenta mas los clusters silhouette no mejora. si genero no esta muy correlación las variables de consumo, puede ser parte de la composición de los clusters, pero necesariamente mejorar la calidad segmentación.

Figura 5

cluster k-means con genero



5.3 Escalado De Variables

Se aplicó StandardScaler a las variables numéricas. Sin escalado, la variable de ingreso podría dominar el cálculo solo por tener una escala más amplia que edad o gasto.

```
array([[ -1.42456879, -1.73899919, -0.43480148],  
       [ -1.28103541, -1.73899919,  1.19570407],  
       [ -1.3528021 , -1.70082976, -1.71591298],  
       [ -1.13750203, -1.70082976,  1.04041783],  
       [ -0.56336851, -1.66266033, -0.39597992]])
```

Cada fila sigue representando un cliente, pero los valores ya no están en años, miles de dólares o escala 1-100. Ahora están expresados como distancia respecto a la media de su variable.

Por ejemplo, en la primera fila:

- **-1.42456879** en edad significa que el cliente está bastante por debajo de la edad promedio.
- **-1.73899919** en ingreso significa que su ingreso está muy por debajo del promedio.
- **-0.43480148** en gasto significa que su gasto está un poco por debajo del promedio.

El escalado es necesario porque K-Means y Agglomerative Clustering dependen de distancias. Sin escalado, una variable con mayor rango podría pesar más aunque no sea más importante.

6. Aplicación Del Primer Algoritmo De Clustering

6.1 Algoritmo Seleccionado

El primer algoritmo fue K-Means.

Se eligió porque es fácil de interpretar, funciona bien con variables numéricas estandarizadas y produce clusters que pueden representarse de forma clara en dos dimensiones.

6.2 Búsqueda Del Número Óptimo De Clusters

Se probaron valores de k entre 2 y 10 usando dos criterios:

- metodo del code
- silhouette score

La lectura de las métricas fue esta:

Tabla 3

Resultados de K-Means por número de clusters

k	Inercia	Silhouette
2	389.386189	0.335472
3	295.212246	0.357793
4	205.225147	0.403958
5	168.247580	0.416643
6	133.868421	0.428417
7	117.011555	0.417232
8	103.873292	0.408207
9	93.092891	0.417693
10	82.385154	0.406554

El mejor silhouette se obtuvo con $k=6$, pero escogí en el notebook $k=5$ por interpretabilidad. Esa decisión fue porque: $k=5$ sigue cerca del mejor valor y permite un relato de negocio más limpio.

Figura 6

Metodo del code





Figura 7

Silhouette score por numero de clusters



6.3 Entrenamiento Del Modelo

Se entreno K-Means con $k=5$, $\text{random_state}=42$ y $n_init=10$.

La configuración final fue estable y reproducible. El modelo asigna a cada cliente un cluster según la cercanía a los centroides.

6.4 Resultados Obtenidos

Figura 8

Clusters obtenidos con K-Means




Tabla 4

Resumen de clusters K-Means

Cluster	Edad media	Ingreso medio (k\$)	Gasto medio	Tamaño
0	46.25	26.75	18.35	20
1	25.19	41.09	62.24	54
2	32.88	86.10	81.53	40
3	39.87	86.10	19.36	39
4	55.64	54.38	48.85	47

6.5 Interpretación De Los Clusters

- Cluster 0: clientes de ingreso bajo y gasto bajo. Es un segmento de bajo valor inmediato.
- Cluster 1: clientes jóvenes con ingreso bajo-medio y gasto medio-alto. Responden mejor a promociones y experiencias.
- Cluster 2: clientes de ingreso alto y gasto alto. Es el segmento más valioso.
- Cluster 3: clientes de ingreso alto y gasto bajo. Tienen capacidad económica, pero no gastan mucho.
- Cluster 4: clientes de edad mayor, ingreso medio y gasto medio. Es un grupo estable, útil para estrategias de retención.

7. Aplicación Del Segundo Algoritmo De Clustering

7.1 Algoritmo Seleccionado

El segundo algoritmo fue Agglomerative Clustering.

Se utilizó porque permite contrastar la estructura obtenida por K-Means con un enfoque jerárquico. Eso ayuda a verificar si los segmentos dependen de un solo método o si la tendencia aparece de forma más general.


7.2 Parâmetros Utilizados

Se empleó clusters=5 para mantener una comparación directa con el modelo K-Means final. La evaluación se hizo con silhouette_score.

7.3 Resultados Obtenidos

Figura 8

Clusters obtenidos con Agglomerative Clustering



El resultado cuantitativo fue:

Metodo	Numero de clusters	Silhouette
K-Means	5	0.416643
Agglomerative Clustering	5	0.390028

7.4 Interpretación De Resultados

Agglomerative Clustering encuentra una estructura parecida a K-Means, pero con menos calidad de separación. En la visualización, algunas zonas centrales quedan repartidas de forma menos limpia. Eso coincide con su silhouette score más bajo.

8. Comparación De Algoritmos

8.1 Comparación Cuantitativa

Tabla 5

Comparación de algoritmos de clustering

Metodo	Numero de clusters	Silhouette score	Facilidad de interpretación	Observaciones
K-Means	5	0.416643	Alta	Segmentos más claros y fáciles de explicar
Agglomerative Clustering	5	0.390028	Media	Válido para contraste, pero menos limpio visualmente

8.2 Comparación Cualitativa

K-Means resultó más fácil de interpretar y dio una separación visual más ordenada. Agglomerative Clustering fue útil como control, pero no superó al modelo principal. Ambos dependen del escalado, pero K-Means se ajustó mejor a la geometría del problema. En este caso, la estructura de los datos parece más cercana a centroides que a una división jerárquica pura.

8.3 Modelo Mas Adecuado

K-Means fue el método más adecuado. No solo obtuvo mejor silhouette, sino que también generó clusters más fáciles de traducir a perfiles de negocio. Para un informe académico o una propuesta comercial, eso pesa tanto como la métrica.

9. Aplicaciones En Un Contexto Real

Los clusters obtenidos pueden usarse para varias decisiones reales:

- segmentación de mercado por comportamiento de compra
- campanas personalizadas según ingreso y gasto
- promociones para clientes de alto ingreso pero bajo gasto
- programas de fidelización para clientes jóvenes con alto gasto
- estrategias de retención para clientes de gasto medio y edad mayor

La utilidad no está en etiquetar clientes por el simple hecho de agruparlos. Está en traducir esos grupos en acciones concretas y distintas. Si todos reciben la misma campana, la segmentación pierde valor.

10. Limitaciones Del Análisis

La primera limitación es el tamaño del dataset. Con 200 clientes se pueden ver tendencias, pero no se debe exagerar la generalización.

La segunda limitación es la cantidad de variables. Solo se usaron edad, ingreso y gasto. Faltan variables de comportamiento más cercanas al negocio, como frecuencia de compra, tipo de producto, ticket promedio o canal de compra.

La tercera limitación es metodológica. K-Means y Agglomerative Clustering funcionan bien aquí, pero no son los únicos enfoques posibles. Otros métodos podrían capturar mejor estructuras irregulares o densidades distintas.

11. Conclusiones

El análisis permitió segmentar clientes de un centro comercial a partir de edad, ingreso anual y puntuación de gasto. La exploración inicial mostró que las variables tienen suficiente variación para justificar clustering. El preprocesamiento fue directo, porque no había nulos ni inconsistencias graves, y el escalado fue suficiente para preparar los datos.

Entre los dos métodos comparados, K-Means dio mejor resultado que Agglomerative Clustering. Aunque el valor óptimo de silhouette aparecía en $k=6$, se eligió $k=5$ por claridad interpretativa. Esa decisión no maximiza la métrica, pero si mejora la lectura de negocio. Para esta actividad, esa elección es defendible.

Los segmentos encontrados son útiles y coherentes: clientes de alto ingreso y alto gasto, clientes con potencial no activado, clientes jóvenes con mayor gasto y clientes de bajo gasto. En una empresa real, esos grupos podrían convertirse en campañas diferenciadas, promociones específicas y estrategias de fidelización más precisas.

Queda una limitación obvia: el dataset es pequeño y tiene pocas variables. Por eso este informe debe leerse como una segmentación inicial, no como una verdad definitiva sobre el comportamiento de todos los clientes.

13. Referencias

Kaggle. (n.d.). *Mall customers dataset* [Data set]. <https://www.kaggle.com/datasets/shwetabh123/mall-customers>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Pandas development team. (n.d.). *pandas documentation*. <https://pandas.pydata.org/docs/>

Scikit-learn developers. (n.d.). *scikit-learn documentation*. <https://scikit-learn.org/stable/>

Waskom, M. L. (n.d.). *seaborn documentation*. <https://seaborn.pydata.org/>